Segmentação Automatizada de Imagens Médicas

Andrea Cecilia[1], Anshu Li[1], Mario Olimpio de Menezes[1]

[1]Universidade Presbiteriana Mackenzie (UPM)
Rua da Consolação, 930 Consolação, São Paulo - SP, 01302-907 - Brasil

{10418084@mackenzista.com.br, 10417673@mackenzista.com.br, mario.menezes@mackenzie.br}

Resumo. *O imageamento médico, especialmente a segmentação e o imageamento volumétrico, é crucial para o diagnóstico, tratamento e avaliação da eficácia do câncer. A aquisição de imagens 3D melhora a precisão dos parâmetros e permite a visualização e mensuração precisas de estruturas, o que é significativo para quantificar a evolução da lesão. Esta pesquisa visa desenvolver tecnologias que simplifiquem os processos de tratamento do câncer. O foco é a segmentação automática de imagens médicas tridimensionais para isolar órgãos danificados, visando acelerar o processo de planejamento da radioterapia.*

Palavras-chaves*: inteligência artificial na saúde; segmentação automática de imagens; aprendizado federado.*

Abstract. *Medical imaging, especially segmentation and volumetric imaging, is crucial for the diagnosis, treatment, and effectiveness assessment of cancer. 3D image acquisition improves parameter accuracy and allows for precise visualization and measurement of structures, which is significant for quantifying lesion progression. This research aims to develop technologies that simplify cancer treatment processes. The focus is on the automatic segmentation of three-dimensional medical images to isolate damaged organs, aiming to accelerate the radiotherapy planning process.*

Keywords*: artificial intelligence in healthcare; automatic image segmentation; federated learning.*

1. Introdução

O câncer é um problema de saúde global, sendo o câncer de próstata particularmente prevalente no Brasil devido à sua alta incidência, mortalidade e custos de tratamento. A radioterapia, que utiliza radiação ionizante, é um método de tratamento eficaz para inibir a proliferação e destruir células tumorais. Apesar dos

inúmeros desafios técnicos, o imageamento médico, especialmente a segmentação e o imageamento volumétrico, é crucial para o diagnóstico, tratamento e avaliação da eficácia do câncer (SANTOS *et al.*, 2023).

A aquisição de imagens 3D consegue aprimorar a precisão dos parâmetros e permite a visualização e mensuração precisas de estruturas, o que é inestimável para quantificar a evolução das lesões (BAJGER, 2013). A inteligência artificial, incluindo aprendizado de máquina, redes neurais convolucionais e visão computacional, constitui a base deste projeto, possibilitando a análise de dados complexos e auxiliando na tomada de decisões (TSAI, 2024).

Esta pesquisa visa desenvolver uma tecnologia que possa aprimorar e simplificar o processo de tratamento do câncer. Ao aplicar algoritmos para segmentar automaticamente imagens médicas e isolar os órgãos afetados, dessa forma a radioterapia pode ser acelerada. Nosso objetivo é continuar a pesquisa de *Aplicação de algoritmo de machine learning para a segmentação automática de imagens médicas com deep learning por meio da técnica de federated learning* (MELO, 2025) que visa desenvolver e validar um algoritmo de machine learning para realizar a segmentação automática da próstata em imagens médicas.

2. Referencial Teórico

2.1 Relevância do tratamento contra o câncer

Atualmente um dos principais problemas da saúde no mundo é o câncer, ele se tornou uma das maiores causas de morte. Se estima que para 2030, "ocorram mais de 25 milhões de casos novos" (SANTOS *et al.*, 2023, p. 1). Para se ter uma ideia, “houve um aumento de 20% na incidência de casos da doença nas últimas décadas” (SANTOS *et al.*, 2023, p. 1). Entre eles, o câncer de próstata (CaP) teve uma incidência de 71 mil novos casos, no Brasil (SANTOS *et al.*, 2023).

Particularmente em países com média e baixa renda, como o é o caso do Brasil, o CaP em específico é um desafio. Isso se deve à alta morbimortalidade e aos altos custos que envolvem o seu tratamento na rede pública e privada de saúde (SANTOS JÚNIOR *et al.*, 2020).

Uma das formas de combater o câncer é por meio de Radioterapia. Nesse tratamento é utilizado radiação ionizante, usado para impedir a multiplicação das células do tumor e destruí-las. Durante todo o procedimento o paciente não sente nenhum incômodo durante o tratamento (BRASIL. INCA, 2023).

O tratamento envolve várias etapas entre elas está a consulta médica inicial, nele o médico oncologista examina o paciente e define o tipo de tratamento mais indicado e indica uma estimativa de quanto tempo durará o tratamento. Na segunda etapa ocorre a programação do tratamento, nessa etapa o paciente realiza uma tomografia na mesma posição em que o tratamento será realizado, para desta forma delimitar a área danificada. Na próxima fase, ocorre o planejamento para o tratamento (Física médica), onde são feitos os cálculos para delimitar o tumor e os órgãos de risco a partir da ressonância magnética. Além de calcular a dose de radiação ideal. Por fim, na última fase após a aprovação do plano o paciente começa realmente o tratamento recebendo a radiação (BRASIL. INCA, 2023).

2.2 Imagens Médicas

As imagens médicas são cruciais para toda a área da saúde, elas auxiliam no processo do diagnóstico, na detecção precoce e no tratamento médico. As imagens médicas são produtos de técnicas e processos que permitem a visualização dos tecidos, órgãos ou sistemas do corpo humano sem a necessidade de procedimentos invasivos, usando um parâmetro de contraste (MELO, 2025; SILVA *et al.*, 2019).

Essa área é fundamental para a detecção e avaliação da resposta para o tratamento de doenças, como o câncer. Dada a sua complexidade, o processamento e a análise digital das imagens não só é relevante como constitui um desafio computacional devido à tentativa de tentar retirar, quantificar e interpretar as informações para obter uma percepção aprofundada sobre a situação médica do paciente (SILVA, *et al.*, 2019).

2.3 Imagens segmentadas

A segmentação de imagem é um processo fundamental que vai além de simples dividir uma imagem. Seu principal objetivo é identificar e isolar regiões de interesse (ROI), transformando dados visuais brutos em informações estruturadas para análise computacional. No contexto médico, isso é de extrema importância. A segmentação permite que os profissionais de saúde concentrem a análise em áreas específicas das imagens para procurar anomalias, examinar características e identificar padrões indicativos de possíveis doenças (SILVA; PATROCÍNIO; SCHIABEL, 2019).

> "A segmentação é considerada uma das tarefas mais difíceis no processamento de imagens, no qual a precisão da segmentação determina o sucesso ou o fracasso dos processos subsequentes de análise computadorizada, classificação e reconhecimento de padrões. Ela pode ser definida como o processo de separação das imagens em regiões com características estruturais similares." (SILVA; PATROCÍNIO; SCHIABEL, 2019, p. 40)

Existem várias métricas para avaliar se a segmentação ocorreu corretamente, entre elas estão a métrica baseada em sobreposição, métricas baseadas em distância espacial entre outros.(TAHA *et al.*, 2015).

2.4 Inteligência Artificial

Algumas tecnologias necessárias para o funcionamento desse projeto são Inteligência artificial, *Deep Learning*, Redes Neurais Convolucionais (CNN), Visão Computacional, ciência de dados, federated learning a *Framework* Flower, iremos revisar esses tópicos e sua importância para o projeto.

A inteligência artificial (IA) executa tarefas e toma decisões que normalmente exigem inteligência humana. É a capacidade de máquinas ou sistemas computacionais de simulação funções cognitivas humanas, como aprendizagem, raciocínio, resolução de problemas, percepção e compreensão da linguagem (TSAI, 2024).

Os *chatbots* ilustram a evolução da IA da comunicação superficial usando sistemas especialistas em 1964 (Eliza), aos assistentes virtuais baseados em PNL em 2010 (Siri e Alexa), até serviços como o OpenAI (GPT-4) que vão muito além dos simples *chatbots* (TSAI, 2024).

Os primeiros avanços da IA tinham poder computacional limitado e algoritmos rudimentares, e sua integração à prática médica era limitada pela tecnologia disponível na época. Desde 2000, o campo da IA se desenvolveu rapidamente, impulsionado pelos avanços em hardware e software de computadores e pela maior acessibilidade da medicina digital (TSAI, 2024).

A visão computacional é um ramo da inteligência artificial (IA) que visa permitir que computadores e sistemas percebam e compreendam imagens digitais, vídeos e outros dados visuais, extraiam informações valiosas deles e, em seguida, tomem decisões e façam recomendações. Seu objetivo final é dotar os computadores de capacidades comparáveis ao sistema visual humano (MATSUZAKA, 2023).

2.5 Machine Learning

O aprendizado de máquina é dividido principalmente em duas categorias, aprendizado supervisionado e aprendizado não supervisionado (HUANG, 2016).

(1) Aprendizado supervisionado: Os dados de treinamento contêm entradas e saídas (recursos e alvos), e a classificação e a predição são obtidas por meio do ajuste contínuo do modelo para reduzir erros. Os métodos comuns incluem análise de regressão e classificação estatística (HUANG, 2016).

(2) Aprendizado não supervisionado: Os dados de treinamento não são rotulados. Um método comum é o agrupamento (como K-means), que estabelece centros de agrupamento interativamente para obter o agrupamento de dados (HUANG, 2016).

O aprendizado de máquina combina inteligência artificial e tecnologias de *big data* e é uma abordagem que contribui para o desenvolvimento de sistemas de computação de alto desempenho na era do *big data*. Tornou-se um ponto de pesquisa e é amplamente utilizado na vida cotidiana, como em busca inteligente, assistentes de voz e inteligência artificial Go (HUANG, 2016).

Deep Learning é um ramo do aprendizado de máquina que permite que computadores aprendam continuamente por meio da experiência e entendam o mundo usando uma estrutura hierárquica de conceitos. Essa hierarquia permite que os computadores combinem e formem gradualmente conceitos mais complexos com base em sua compreensão de conceitos básicos, aprendendo e representando conhecimento complexo (GOODFELLOW, 2016).

Redes neurais convolucionais (CNNs) são um tipo de modelo de aprendizado profundo composto por múltiplas camadas de redes neurais que extraem automaticamente padrões, características e representações de dados brutos. O aprendizado profundo se destaca no processamento de dados não estruturados, como imagens, fala e texto, e alcançou progressos significativos em áreas como reconhecimento de imagens, processamento de linguagem natural e reconhecimento de fala (TSAI, 2024).

2.6 Ciência de Dados

O avanço e a ampla aplicação das TICs têm impactado significativamente o comportamento social coletivo, desencadeando extensas discussões no campo da ciência da informação. Essas discussões concentram-se principalmente em como utilizar eficazmente os dados, as informações e o conhecimento gerados a partir dos rastros digitais produzidos por dispositivos computacionais (como câmeras, telefones celulares, cartões de crédito e diversos sensores). Como um campo interdisciplinar emergente, o objetivo principal da ciência de dados é extrair informações úteis de bancos de dados grandes, complexos, dinâmicos, heterogêneos e distribuídos (RAUTENBERG *et al*., 2019).

A Lei Geral de Proteção de Dados (LGPD), ou Lei nº 13.709/2018, visa proteger os direitos fundamentais dos indivíduos à liberdade, à privacidade e à liberdade de expressão. Esta lei estipula as obrigações de pessoas físicas ou jurídicas no que diz respeito à gestão e proteção dos dados pessoais coletados, armazenados, tratados e compartilhados em formato físico ou digital, sob o direito público ou

privado, abrangendo diversas formas de atividades de tratamento de dados, incluindo operações manuais e digitais (MINISTÉRIO DO ESPORTE, 2024).

Atualmente, contamos com várias legislações rigorosas que regulamentam a privacidade e segurança de dados, para ter um programa de ciência de dados adequado é necessário ter um grande banco de dados e essas legislações podem comprometer a fidelidade do programa.

2.7 Éticas do uso da IA

A aplicação da inteligência artificial (IA) na área da saúde ampliou significativamente o potencial dos serviços médicos e da tomada de decisões pelos médicos, graças à sua capacidade de processar grandes volumes de dados. No entanto, a falta de transparência em muitas tecnologias e as camadas ocultas de tomada de decisão dificultam a supervisão humana direta e eficaz. Portanto, garantir a robustez, a segurança, a imparcialidade e a confiabilidade dos sistemas de IA com base em princípios éticos é crucial. As preocupações com a segurança da IA concentram-se em como desenvolver IA que beneficie a humanidade e nos lembram que sistemas de IA que se desviam dos valores humanos podem ter consequências indesejadas (Corrêa, 2025) .

Assim, garantir que os sistemas de IA estejam em conformidade com os ideais éticos na área da saúde exige mais do que apenas monitorar ou regular seu comportamento. Os ideais e conceitos éticos geralmente precisam ser integrados em todas as etapas do ciclo de vida da IA, desde a concepção e o desenvolvimento até a implementação (Ossa,2024).

3. Metodologia

A pesquisa se caracteriza como aplicada com objetivo prático de aprimorar o planejamento da radioterapia. Quanto aos fins, trata-se de um estudo exploratório descritivo, o delineamento da pesquisa é de desenvolvimento foca na criação de um algoritmo de deep learning para a transição de imagens bidimensionais para volumétricas. A natureza dos dados é predominantemente quantitativa, baseada em métricas de avaliação de segmentação e análise estatística da precisão do modelo. (GIL *et al.,* 2022)

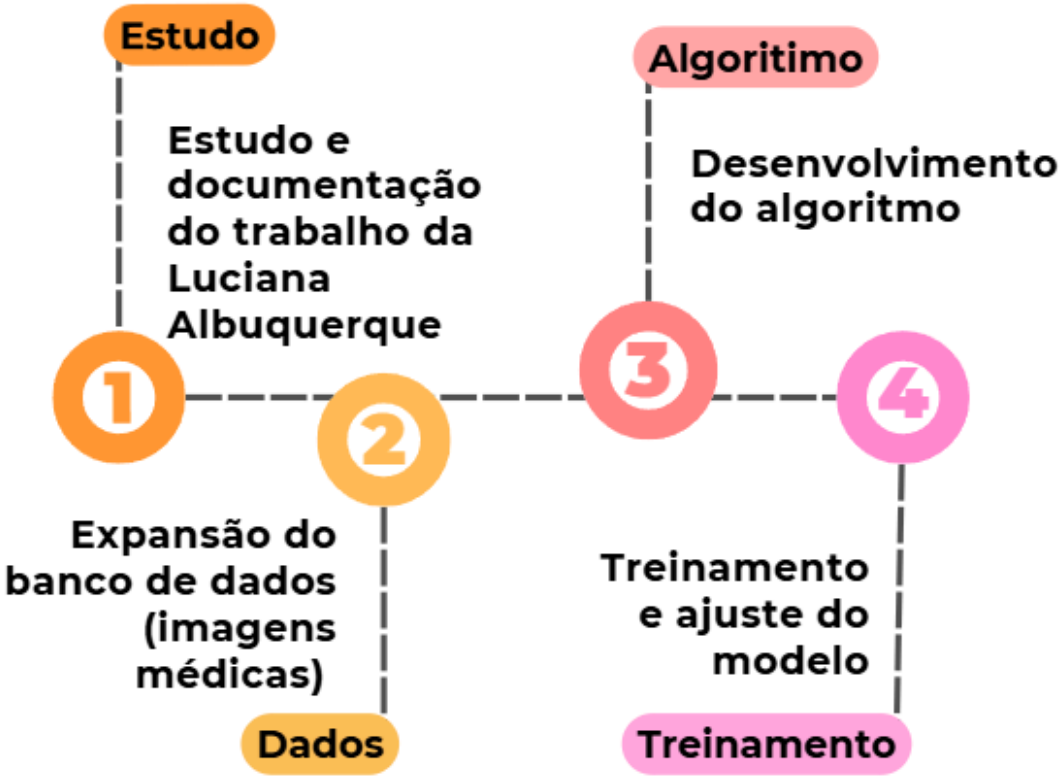

Figura 1: Ciclo de Vida do Projeto

Fonte: Elaborado pelo autor

As etapas que serão desenvolvidas ao longo do projeto são quatro, como pode ser visto na figura 1. As etapas são: estudo de caso; junção dos dados para o projeto; desenvolvimento e modificação do algoritmo; treinamento da máquina.

1. Estudo e documentação do trabalho da *Aplicação de algoritmo de machine learning para a segmentação automática de imagens médicas com deep learning por meio da técnica de federated learning* (MELO, 2025)

A primeira fase consiste na revisão e análise detalhada das dissertações, essa etapa é essencial para compreender as configurações e métricas usadas, servindo como ponto de partida e base comparativa para desenvolver a continuação do projeto. Revisão e análise da dissertação de Albuquerque (2025), Aplicação de algoritmo de *machine learning* para a segmentação automática de imagens médicas com deep learning por meio da técnica de *federated learning*. Documentar a arquitetura da Rede neural Convolucional (CNN)(MELO, 2025).

2. Expansão do banco de dados (imagens médicas)

A segunda etapa é importante para aumentar a capacidade de generalização do novo modelo, complementando as bases já utilizadas. Selecionar e buscar ativamente em repositórios por imagens médicas focando em câncer de próstata (CaP), Organizar os novos dados garantindo que estejam no formato correto e por fim realizar o pré-processamento antes da entrada no modelo (MELO, 2025; SILVA *et al.*, 2019).

2.1 Dataset

O presente trabalho utiliza um conjunto de dados composto por imagens médicas tridimensionais, disponibilizadas no formato MetaImage (.mhd) juntamente com seus respectivos arquivos binários (.raw). Além das imagens originais, o conjunto de dados inclui máscaras de segmentação associadas a cada exame, as quais indicam as regiões de interesse por meio de valores binários (Litjens, 2023).

O dataset é dividido em 49 casos destinados ao treinamento e 11 casos reservados para teste, totalizando 60 exames de pacientes distintos. Essa separação possibilita a avaliação do modelo em dados não vistos previamente, contribuindo para uma análise mais realista de seu desempenho (Litjens, 2023).

2.2 Análise exploratória e preparação de dados

No âmbito da análise exploratória, serão executadas as seguintes atividades de diagnóstico e tratamento de dados:

- Verificação do formato: tamanho do volume para entender a resolução espacial da imagem (ex. 20 fatias de 320x320 pixels);
- Valor máximo de cor e Distribuição de Tons (Histograma): Foi verificado o valor máximo decor presente na imagem;
- Visualização inicia: Exibição de uma fatia específica da imagem;
- Carregar a imagem original e a segmentação: ler os arquivos de imagem e a máscara correspondente (segmentação) em determinada fatia;
- Máscara sobreposta à Imagem Original: visualizar fatias específicas onde a máscara de segmentação é sobreposta à imagem original, permitindo validar visualmente se a segmentação corresponde à anatomia;
- Tabela de Consistência(Mostra média, min, max de todos os casos): criação de uma tabela que resume estatísticas de múltiplos casos, apresentando valores de média, mínimo e máximo das intensidades de pixels para garantir que os dados de todos os pacientes sigam um padrão consistente;

- Gráfico de Volume das Segmentações: gerar de um gráfico que compara o volume total ocupado pela segmentação em cada caso, permitindo identificar variações anatômicas ou outliers entre os pacientes;
- Histograma de Comparação: sorteio aleatório de 3 casos para a criação de histogramas de intensidade de pixels, comparando a distribuição das frequências de cores entre a imagem original e as áreas segmentadas.

3. Desenvolvimento do algoritmo

Na terceira etapa o modelo será adaptado para a segmentação do grande volume de imagens. Implementamos o modelo para gerar a segmentação. (BAJGER, 2013).

4. Treinamento e ajuste do modelo

Na quarta etapa, visamos o treinamento e ajuste do modelo. Iniciaremos o treinamento do novo modelo, aplicando os dados da etapa 2. Realizar ajustes para melhorar a precisão (REDI *et al.*, 2020).

4.Resultados Esperados

Ao final deste projeto espera-se concluir o desenvolvimento e a validação de um algoritmo de machine learning capaz de realizar a segmentação automática da próstata em imagens médicas, sendo capaz de isolar com sucesso os órgãos afetados, facilitando a aplicação da radiação ionizante de forma mais direcionada .

E que dessa forma resulte numa redução significativa do tempo necessário para a etapa de planejamento da radioterapia. Além disso, conseguir que a utilização da inteligência artificial permita uma visualização e mensuração mais precisas das estruturas e lesões, melhorando a precisão dos parâmetros clínicos e sua eficiência, assim auxiliando os profissionais de saúde na tomada de decisões complexas.

5.Referências Bibliográficas

MELO, L. S. A. Aplicação de algoritmo de machine learning para a segmentação automática de imagens médicas com deep learning por meio da técnica de federated learning. Dissertação (Mestrado em Tecnologia Nuclear), IPEN-CNEN, São Paulo, 2025. Acesso em: 26 de Setembro de 2025.

SANTOS, Marceli de Oliveira et al. Estimativa de Incidência de Câncer no Brasil, 2023-2025. Revista Brasileira de Cancerologia, Rio de Janeiro, v. 69, n. 1, p. e-213700, 2023. Disponível em: https://rbc.inca.gov.br/index.php/revista/article/view/3700. Acesso em: 26 de Setembro de 2025.

DOS SANTOS JÚNIOR, Claudio José; TÔRRES OLIVEIRA, Elaine Cristina. [ID 51955] MORBIMORTALIDADE POR CÂNCER DE PRÓSTATA EM HOMENS ADULTOS EM UM ESTADO DO NORDESTE DO BRASIL: CARACTERIZAÇÃO EPIDEMIOLÓGICA E ANÁLISE DE TENDÊNCIA TEMPORAL: MORBIMORTALITY FROM PROSTATE CANCER IN ADULT MEN IN A STATE OF NORTHEAST BRAZIL: EPIDEMIOLOGICAL CHARACTERIZATION AND TEMPORAL TREND ANALYSIS. Revista Brasileira de Ciências da Saúde, [S. l.], v. 24, n. 4, 2020. DOI: 10.22478/ufpb.2317-6032.2020v24n4.51955. Disponível em: https://periodicos.ufpb.br/index.php/rbcs/article/view/51955. Acesso em: 27 set. 2025.

BRASIL. Instituto Nacional de Câncer. Radioterapia. Rio de Janeiro: INCA, [2023]. Disponível em: https://www.gov.br/inca/pt-br/assuntos/cancer/tratamento/radioterapia. Acesso em: 26 de Setembro de 2025.

MARQUES DA SILVA, Ana Maria; PATROCÍNIO, Ana Cláudia; SCHIABEL, Homero. Processamento e Análise de Imagens Médicas. Revista Brasileira de Física Médica, [S. l.], v. 13, n. 1, p. 34–48, 2019. DOI: 10.29384/rbfm.2019.v13.n1.p34-48. Disponível em: https://www.rbfm.org.br/rbfm/article/view/525. Acesso em: 28 set. 2025.

Taha, A.A., Hanbury, A. Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool. BMC Med Imaging 15, 29 (2015). Disponível em: https://doi.org/10.1186/s12880-015-0068-x . Acesso em: 28 set. 2025.

BAJGER, Mariusz; LEE, Gobert; CAON, Martin. 3D Segmentation for Multi-Organs in CT Images. ELCVIA Electronic Letters on Computer Vision and Image Analysis, Cerdayola del Vallès, Spain, v. 12, n. 2, p. 13–27, 2013. DOI: 10.5565/rev/elcvia.516. Disponível em: https://elcvia.cvc.uab.cat/article/view/v12-n2-bajger-lee-caon. Acesso em: 28 sep. 2025.

RAUTENBERG, Sandro; CARMO, Paulo Ricardo Viviurka do. Big data e ciência de dados: complementaridade conceitual no processo de tomada de decisão. Brazilian Journal of Information Science: research trends, Marília, SP, v. 13, n. 1, p. 56–67, 2019. DOI: 10.36311/1981-1640.2019.v13n1.06.p56. Disponível em: https://revistas.marilia.unesp.br/index.php/bjis/article/view/8315. Acesso em: 28 set. 2025.

BRASIL. Ministério do Esporte. Lei Geral de Proteção de Dados (LGPD). Brasília, 2024. Disponível em: https://www.gov.br/esporte/pt-br/acesso-a-informacao/lgpd. Acesso em: 28 set. 2025.

MATSUZAKA, Y. AI-Based Computer Vision Techniques and Expert Systems. AI, [S. l.], v. 4, n. 1, p. 289-302, 2023. Disponível em: https://doi-org.ez347.periodicos.capes.gov.br/10.3390/ai4010013.. Acesso em: 25 set. 2025.

FARAGALLAH, O. S.; EL-HOSENY, H. M.; EL-SAYED, H. S. Efficient brain tumor segmentation using OTSU and K-means clustering in homomorphic transform. Biomedical Signal Processing and Control, v. 85, 2023. Disponível em: https://www-sciencedirect-com.ez347.periodicos.capes.gov.br/science/article/pii/S1746809423001453. Acesso em: 25 set. 2025.

Tsai A. Y. Artificial intelligence in pediatric surgery. Seminars in Pediatric Surgery, 2024, v. 33, n. 1, p. 7, 2024.Disponível em: https://doi-org.ez347.periodicos.capes.gov.br/10.1016/j.sempedsurg.2024.151390. Acesso em: 25 set. 2025.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Deep Learning; MIT Press: Cambridge, MA, USA, 2016. Disponível em: < https://scholar.google.com/scholar_lookup?title=Deep+Learning&author=Goodfellow, +I.&author=Bengio,+Y.&author=Courville,+A.&publication_year=2016>. Acesso em 28 de set de 2025.

Technology in Artificial Intelligence. Computational Intelligence and Neuroscience, [S. l.], v. 2022, ID 5658641, 2022. Disponível em: https://onlinelibrary.wiley.com/doi/10.1155/2022/5658641. Acesso em: 28 de set de 2025.

CARITÁ, E. C.; MATOS, A. L. M.; AZEVEDO-MARQUES, P. M. Ferramentas para visualização de imagens médicas em hospital universitário. Revista Brasileira de Radiologia, São Paulo, v. 37, n. 4, p. 273-278, ago. 2004. Disponível em: https://www.scielo.br/j/rb/a/pxsZnf4VPknBTkHJ8FmTnrB/?lang=pt. Acesso em: 28 de set de 2025.

TOP, Andrew; HAMARNEH, Ghassan; ABUGHARBIEH, Rafeeh. Active Learning for Interactive 3D Image Segmentation. In: FICHTINGER, Gabor; MARTEL, Anne; PETERS, Terry (Ed.). Medical Image Computing and Computer-Assisted Intervention – MICCAI 2011: 14th International Conference, Toronto, Canada, September 18-22, 2011, PROCEEDINGS, Part III. Heidelberg: Springer-Verlag, 2011. p. 603-610. (Lecture Notes in Computer Science, 6893). Disponível em:

https://link.springer.com/chapter/10.1007/978-3-642-23626-6_74. Acesso em:14 de nov de 2025.

FREIHERR, G. : 3D imaging in medicine : synthesizing the third dimension. Diagnostic Imaging 9, 190-203 (November 1987) Galloway, L. and Thurstone, F.L. : Recent applications of parallel processing techniques to improve ultrasound B-mode images. Ultrasonic Imaging 8, n 1, p 69 (1986). Acesso em: 14 de nov de 2025.

HÖHNE, Karl H.; FUCHS, Henry; PIZER, Stephen M. (Ed.). 3D Imaging in Medicine: Algorithms, Systems, Applications. Berlin: Springer-Verlag, 1990. (NATO ASI Series F: Computer and Systems Sciences, v. 60). Disponível em: https://link-springer-com.ez347.periodicos.capes.gov.br/book/10.1007/978-3-642-84211-5. Acesso em: 14 de nov de 2025.

GIL, A. C. Como elaborar projetos de pesquisa. 7. ed. Baurieri, SP: Atlas, 2022. Acesso em: 16 de nov de 2025.

Arbelaez Ossa, L., Lorenzini, G., Milford, S.R. et al. Integrating ethics in AI development: a qualitative study. BMC Med Ethics 25, 10 (2024). https://doi.org/10.1186/s12910-023-01000-0. Acesso em: 20 de mar de 2026.

Corrêa, N.K., Santos, J.W., Galvão, C. et al. Crossing the principle–practice gap in AI ethics with ethical problem-solving. AI Ethics 5, 1271–1288 (2025). https://doi.org/10.1007/s43681-024-00469-8, Acesso em: 20 de mar de 2026.

Geert Litjens, Bram van Ginneken, Henkjan Huisman, Wendy van de Ven, Caroline Hoeks, Dean Barratt, & Anant Madabhushi. (2023). PROMISE12: Data from the MICCAI Grand Challenge: Prostate MR Image Segmentation 2012 [Data set]. In Medical Image Analysis (Updated the zip files, fixed some issues., Vol. 18, Número 2, p. 359–373). Zenodo. https://doi.org/10.5281/zenodo.8026660. Acesso em: 20 de mar de 2026.