Segmentação Automatizada de Imagens Médicas

Andrea Cecilia[1], Anshu Li[1], Mario Olimpio de Menezes[1]

[1]Universidade Presbiteriana Mackenzie (UPM)
Rua da Consolação, 930 Consolação, São Paulo - SP, 01302-907 - Brasil

{10418084@mackenzista.com.br, 10417673@mackenzista.com.br, mario.menezes@mackenzie.br}

Resumo

O imageamento médico, especialmente a segmentação e o imageamento volumétrico, é crucial para o diagnóstico, tratamento e avaliação da eficácia do câncer. A aquisição de imagens 3D melhora a precisão dos parâmetros e permite a visualização e mensuração precisas de estruturas, o que é significativo para quantificar a evolução da lesão. Esta pesquisa visa desenvolver tecnologias que simplifiquem os processos de tratamento do câncer. O foco é a segmentação automática de imagens médicas tridimensionais para isolar órgãos danificados, visando acelerar o processo de planejamento da radioterapia.

1. Introdução

O câncer é um problema de saúde global, sendo o câncer de próstata particularmente prevalente no Brasil devido à sua alta incidência, mortalidade e custos de tratamento. A radioterapia, que utiliza radiação ionizante, é um método de tratamento eficaz para inibir a proliferação e destruir células tumorais. Apesar dos inúmeros desafios técnicos, o imageamento médico, especialmente a segmentação e o imageamento volumétrico, é crucial para o diagnóstico, tratamento e avaliação da eficácia do câncer (SANTOS *et al.*, 2023).

A aquisição de imagens 3D consegue aprimorar a precisão dos parâmetros e permite a visualização e mensuração precisas de estruturas, o que é inestimável para quantificar a evolução das lesões (BAJGER, 2013). A inteligência artificial, incluindo aprendizado de máquina, redes neurais convolucionais e visão computacional, constitui a base deste projeto, possibilitando a análise de dados complexos e auxiliando na tomada de decisões (TSAI, 2024).

Esta pesquisa visa desenvolver uma tecnologia que possa aprimorar e simplificar o processo de tratamento do câncer. Ao aplicar algoritmos para segmentar automaticamente imagens médicas e isolar os órgãos afetados, dessa forma a radioterapia pode ser acelerada. Nosso objetivo é continuar a pesquisa de *Aplicação de algoritmo de machine learning para a segmentação automática de imagens médicas com deep learning por meio da técnica de federated learning* (MELO, 2025)

que visa desenvolver e validar um algoritmo de machine learning para realizar a segmentação automática da próstata em imagens médicas.

2. Referencial Teórico

2.1 Relevância do tratamento contra o câncer

Atualmente um dos principais problemas da saúde no mundo é o câncer, ele se tornou uma das maiores causas de morte. Se estima que para 2030, "ocorram mais de 25 milhões de casos novos" (SANTOS *et al*., 2023, p. 1). Para se ter uma ideia, “houve um aumento de 20% na incidência de casos da doença nas últimas décadas” (SANTOS *et al.*, 2023, p. 1). Entre eles, o câncer de próstata (CaP) teve uma incidência de 71 mil novos casos, no Brasil (SANTOS *et al.*, 2023).

Particularmente em países com média e baixa renda, como o é o caso do Brasil, o CaP em específico é um desafio. Isso se deve à alta morbimortalidade e aos altos custos que envolvem o seu tratamento na rede pública e privada de saúde (SANTOS JÚNIOR *et al.*, 2020).

Uma das formas de combater o câncer é por meio de Radioterapia. Nesse tratamento é utilizado radiação ionizante, usado para impedir a multiplicação das células do tumor e destruí-las. Durante todo o procedimento o paciente não sente nenhum incômodo durante o tratamento (BRASIL. INCA, 2023).

O tratamento envolve várias etapas entre elas está a consulta médica inicial, nele o médico oncologista examina o paciente e define o tipo de tratamento mais indicado e indica uma estimativa de quanto tempo durará o tratamento. Na segunda etapa ocorre a programação do tratamento, nessa etapa o paciente realiza uma tomografia na mesma posição em que o tratamento será realizado, para desta forma delimitar a área danificada. Na próxima fase, ocorre o planejamento para o tratamento (Física médica), onde são feitos os cálculos para delimitar o tumor e os órgãos de risco a partir da ressonância magnética. Além de calcular a dose de radiação ideal. Por fim, na última fase após a aprovação do plano o paciente começa realmente o tratamento recebendo a radiação (BRASIL. INCA, 2023).

2.2 Imagens Médicas

As imagens médicas são cruciais para toda a área da saúde, elas auxiliam no processo do diagnóstico, na detecção precoce e no tratamento médico. As imagens médicas são produtos de técnicas e processos que permitem a visualização dos tecidos, órgãos ou sistemas do corpo humano sem a necessidade de procedimentos invasivos, usando um parâmetro de contraste (MELO, 2025; SILVA *et al.*, 2019).

Essa área é fundamental para a detecção e avaliação da resposta para o tratamento de doenças, como o câncer. Dada a sua complexidade, o processamento e a análise digital das imagens não só é relevante como constitui um desafio computacional devido à tentativa de tentar retirar, quantificar e interpretar as informações para obter uma percepção aprofundada sobre a situação médica do paciente (SILVA, *et al.*, 2019).

2.3 Imagens segmentadas

A segmentação de imagem é um processo fundamental que vai além de simples dividir uma imagem. Seu principal objetivo é identificar e isolar regiões de interesse (ROI), transformando dados visuais brutos em informações estruturadas para análise computacional. No contexto médico, isso é de extrema importância. A segmentação permite que os profissionais de saúde concentrem a análise em áreas específicas das imagens para procurar anomalias, examinar características e identificar padrões indicativos de possíveis doenças (SILVA; PATROCÍNIO; SCHIABEL, 2019).

> "A segmentação é considerada uma das tarefas mais difíceis no processamento de imagens, no qual a precisão da segmentação determina o sucesso ou o fracasso dos processos subsequentes de análise computadorizada, classificação e reconhecimento de padrões. Ela pode ser definida como o processo de separação das imagens em regiões com características estruturais similares." (SILVA; PATROCÍNIO; SCHIABEL, 2019, p. 40)

Existem várias métricas para avaliar se a segmentação ocorreu corretamente, entre elas estão a métrica baseada em sobreposição, métricas baseadas em distância espacial entre outros.(TAHA *et al.*, 2015).

2.4 Inteligência Artificial

Algumas tecnologias necessárias para o funcionamento desse projeto são Inteligência artificial, *Deep Learning*, Redes Neurais Convolucionais (CNN), Visão Computacional, ciência de dados, federated learning a *Framework* Flower, iremos revisar esses tópicos e sua importância para o projeto.

A inteligência artificial (IA) executa tarefas e toma decisões que normalmente exigem inteligência humana. É a capacidade de máquinas ou sistemas computacionais de simulação funções cognitivas humanas, como aprendizagem, raciocínio, resolução de problemas, percepção e compreensão da linguagem (TSAI, 2024).

Os *chatbots* ilustram a evolução da IA da comunicação superficial usando sistemas especialistas em 1964 (Eliza), aos assistentes virtuais baseados em PNL em

2010 (Siri e Alexa), até serviços como o OpenAI (GPT-4) que vão muito além dos simples *chatbots* (TSAI, 2024).

Os primeiros avanços da IA tinham poder computacional limitado e algoritmos rudimentares, e sua integração à prática médica era limitada pela tecnologia disponível na época. Desde 2000, o campo da IA se desenvolveu rapidamente, impulsionado pelos avanços em hardware e software de computadores e pela maior acessibilidade da medicina digital (TSAI, 2024).

A visão computacional é um ramo da inteligência artificial (IA) que visa permitir que computadores e sistemas percebam e compreendam imagens digitais, vídeos e outros dados visuais, extraiam informações valiosas deles e, em seguida, tomem decisões e façam recomendações. Seu objetivo final é dotar os computadores de capacidades comparáveis ao sistema visual humano (MATSUZAKA, 2023).

2.5 Machine Learning

O aprendizado de máquina é dividido principalmente em duas categorias, aprendizado supervisionado e aprendizado não supervisionado (HUANG, 2016).

(1) Aprendizado supervisionado: Os dados de treinamento contêm entradas e saídas (recursos e alvos), e a classificação e a predição são obtidas por meio do ajuste contínuo do modelo para reduzir erros. Os métodos comuns incluem análise de regressão e classificação estatística (HUANG, 2016).

(2) Aprendizado não supervisionado: Os dados de treinamento não são rotulados. Um método comum é o agrupamento (como K-means), que estabelece centros de agrupamento interativamente para obter o agrupamento de dados (HUANG, 2016).

O aprendizado de máquina combina inteligência artificial e tecnologias de *big data* e é uma abordagem que contribui para o desenvolvimento de sistemas de computação de alto desempenho na era do *big data*. Tornou-se um ponto de pesquisa e é amplamente utilizado na vida cotidiana, como em busca inteligente, assistentes de voz e inteligência artificial Go (HUANG, 2016).

Deep Learning é um ramo do aprendizado de máquina que permite que computadores aprendam continuamente por meio da experiência e entendam o mundo usando uma estrutura hierárquica de conceitos. Essa hierarquia permite que os computadores combinem e formem gradualmente conceitos mais complexos com base em sua compreensão de conceitos básicos, aprendendo e representando conhecimento complexo (GOODFELLOW, 2016).

Redes neurais convolucionais (CNNs) são um tipo de modelo de aprendizado profundo composto por múltiplas camadas de redes neurais que extraem automaticamente padrões, características e representações de dados brutos. O aprendizado profundo se destaca no processamento de dados não estruturados, como imagens, fala e texto, e alcançou progressos significativos em áreas como reconhecimento de imagens, processamento de linguagem natural e reconhecimento de fala (TSAI, 2024).

2.6 Ciência de Dados

O avanço e a ampla aplicação das TICs têm impactado significativamente o comportamento social coletivo, desencadeando extensas discussões no campo da ciência da informação. Essas discussões concentram-se principalmente em como utilizar eficazmente os dados, as informações e o conhecimento gerados a partir dos rastros digitais produzidos por dispositivos computacionais (como câmeras, telefones celulares, cartões de crédito e diversos sensores). Como um campo interdisciplinar emergente, o objetivo principal da ciência de dados é extrair informações úteis de bancos de dados grandes, complexos, dinâmicos, heterogêneos e distribuídos (RAUTENBERG *et al*., 2019).

A Lei Geral de Proteção de Dados (LGPD), ou Lei nº 13.709/2018, visa proteger os direitos fundamentais dos indivíduos à liberdade, à privacidade e à liberdade de expressão. Esta lei estipula as obrigações de pessoas físicas ou jurídicas no que diz respeito à gestão e proteção dos dados pessoais coletados, armazenados, tratados e compartilhados em formato físico ou digital, sob o direito público ou privado, abrangendo diversas formas de atividades de tratamento de dados, incluindo operações manuais e digitais (MINISTÉRIO DO ESPORTE, 2024).

Atualmente, contamos com várias legislações rigorosas que regulamentam a privacidade e segurança de dados, para ter um programa de ciência de dados adequado é necessário ter um grande banco de dados e essas legislações podem comprometer a fidelidade do programa.

2.7 Éticas do uso da IA

A aplicação da inteligência artificial (IA) na área da saúde ampliou significativamente o potencial dos serviços médicos e da tomada de decisões pelos médicos, graças à sua capacidade de processar grandes volumes de dados. No entanto, a falta de transparência em muitas tecnologias e as camadas ocultas de tomada de decisão dificultam a supervisão humana direta e eficaz. Portanto, garantir a robustez, a segurança, a imparcialidade e a confiabilidade dos sistemas de IA com base em princípios éticos é crucial. As preocupações com a segurança da IA concentram-se em

como desenvolver IA que beneficie a humanidade e nos lembram que sistemas de IA que se desviam dos valores humanos podem ter consequências indesejadas (Corrêa, 2025) .

Assim, garantir que os sistemas de IA estejam em conformidade com os ideais éticos na área da saúde exige mais do que apenas monitorar ou regular seu comportamento. Os ideais e conceitos éticos geralmente precisam ser integrados em todas as etapas do ciclo de vida da IA, desde a concepção e o desenvolvimento até a implementação (Ossa,2024).

3. Metodologia

A pesquisa se caracteriza como aplicada com objetivo prático de aprimorar o planejamento da radioterapia. Quanto aos fins, trata-se de um estudo exploratório descritivo, o delineamento da pesquisa é de desenvolvimento foca na criação de um algoritmo de deep learning para a transição de imagens bidimensionais para volumétricas. A natureza dos dados é predominantemente quantitativa, baseada em métricas de avaliação de segmentação e análise estatística da precisão do modelo. (GIL *et al.,* 2022)

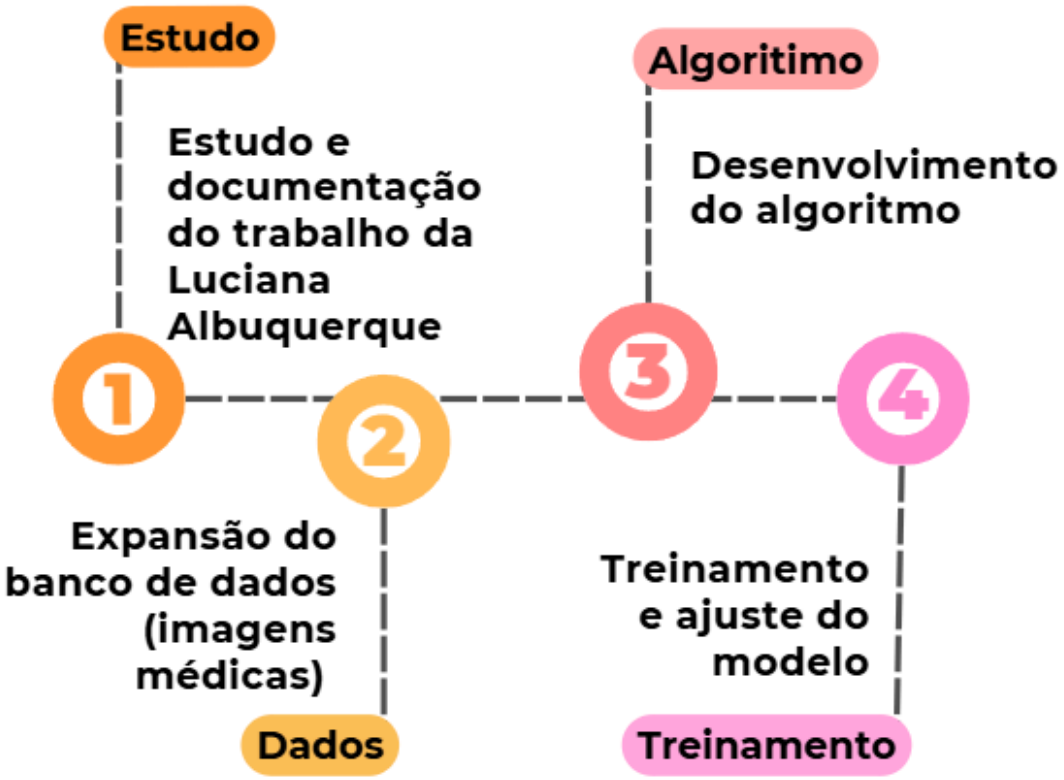

Figura 1: Ciclo de Vida do Projeto

Fonte: Elaborado pelo autor

As etapas que serão desenvolvidas ao longo do projeto são quatro, como pode ser visto na figura 1. As etapas são: estudo de caso; junção dos dados para o projeto; desenvolvimento e modificação do algoritmo; treinamento da máquina.

1. Estudo e documentação do trabalho da *Aplicação de algoritmo de machine learning para a segmentação automática de imagens médicas com deep learning por meio da técnica de federated learning* (MELO, 2025)

A primeira fase consiste na revisão e análise detalhada das dissertações, essa etapa é essencial para compreender as configurações e métricas usadas, servindo como ponto de partida e base comparativa para desenvolver a continuação do projeto. Revisão e análise da dissertação de Albuquerque (2025), Aplicação de algoritmo de *machine learning* para a segmentação automática de imagens médicas com deep learning por meio da técnica de *federated learning*. Documentar a arquitetura da Rede neural Convolucional (CNN)(MELO, 2025).

2. Expansão do banco de dados (imagens médicas)

A segunda etapa é importante para aumentar a capacidade de generalização do novo modelo, complementando as bases já utilizadas. Selecionar e buscar ativamente em repositórios por imagens médicas focando em câncer de próstata (CaP), Organizar os novos dados garantindo que estejam no formato correto e por fim realizar o pré-processamento antes da entrada no modelo (MELO, 2025; SILVA *et al.*, 2019).

3. Desenvolvimento do algoritmo

Na terceira etapa o modelo será adaptado para a segmentação do grande volume de imagens. Implementamos o modelo para gerar a segmentação. (BAJGER, 2013).

4. Treinamento e ajuste do modelo

Na quarta etapa, visamos o treinamento e ajuste do modelo. Iniciaremos o treinamento do novo modelo, aplicando os dados da etapa 2. Realizar ajustes para melhorar a precisão (REDI *et al.*, 2020).

4.Resultados Esperados

Ao final deste projeto espera-se concluir o desenvolvimento e a validação de um algoritmo de machine learning capaz de realizar a segmentação automática da próstata em imagens médicas, sendo capaz de isolar com sucesso os órgãos afetados, facilitando a aplicação da radiação ionizante de forma mais direcionada .

E que dessa forma resulte numa redução significativa do tempo necessário para a etapa de planejamento da radioterapia. Além disso, conseguir que a utilização da inteligência artificial permita uma visualização e mensuração mais precisas das estruturas e lesões, melhorando a precisão dos parâmetros clínicos e sua eficiência, assim auxiliando os profissionais de saúde na tomada de decisões complexas.

5.Referências Bibliográficas

MELO, L. S. A. Aplicação de algoritmo de machine learning para a segmentação automática de imagens médicas com deep learning por meio da técnica de federated learning. Dissertação (Mestrado em Tecnologia Nuclear), IPEN-CNEN, São Paulo, 2025. Acesso em: 26 de Setembro de 2025.

SANTOS, Marceli de Oliveira et al. Estimativa de Incidência de Câncer no Brasil, 2023-2025. Revista Brasileira de Cancerologia, Rio de Janeiro, v. 69, n. 1, p. e-213700, 2023. Disponível em: https://rbc.inca.gov.br/index.php/revista/article/view/3700. Acesso em: 26 de Setembro de 2025.

DOS SANTOS JÚNIOR, Claudio José; TÔRRES OLIVEIRA, Elaine Cristina. [ID 51955] MORBIMORTALIDADE POR CÂNCER DE PRÓSTATA EM HOMENS ADULTOS EM UM ESTADO DO NORDESTE DO BRASIL: CARACTERIZAÇÃO EPIDEMIOLÓGICA E ANÁLISE DE TENDÊNCIA TEMPORAL: MORBIMORTALITY FROM PROSTATE CANCER IN ADULT MEN IN A STATE OF NORTHEAST BRAZIL: EPIDEMIOLOGICAL CHARACTERIZATION AND TEMPORAL TREND ANALYSIS. Revista Brasileira de Ciências da Saúde, [S. l.], v. 24, n. 4, 2020. DOI: 10.22478/ufpb.2317-6032.2020v24n4.51955. Disponível em: https://periodicos.ufpb.br/index.php/rbcs/article/view/51955. Acesso em: 27 set. 2025.

BRASIL. Instituto Nacional de Câncer. Radioterapia. Rio de Janeiro: INCA, [2023]. Disponível em: https://www.gov.br/inca/pt-br/assuntos/cancer/tratamento/radioterapia. Acesso em: 26 de Setembro de 2025.

MARQUES DA SILVA, Ana Maria; PATROCÍNIO, Ana Cláudia; SCHIABEL, Homero. Processamento e Análise de Imagens Médicas. Revista Brasileira de Física Médica, [S. l.], v. 13, n. 1, p. 34–48, 2019. DOI: 10.29384/rbfm.2019.v13.n1.p34-48.

Disponível em: https://www.rbfm.org.br/rbfm/article/view/525. Acesso em: 28 set. 2025.

Taha, A.A., Hanbury, A. Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool. BMC Med Imaging 15, 29 (2015). Disponível em: https://doi.org/10.1186/s12880-015-0068-x . Acesso em: 28 set. 2025.

BAJGER, Mariusz; LEE, Gobert; CAON, Martin. 3D Segmentation for Multi-Organs in CT Images. ELCVIA Electronic Letters on Computer Vision and Image Analysis, Cerdayola del Vallès, Spain, v. 12, n. 2, p. 13–27, 2013. DOI: 10.5565/rev/elcvia.516. Disponível em: https://elcvia.cvc.uab.cat/article/view/v12-n2-bajger-lee-caon. Acesso em: 28 sep. 2025.

RAUTENBERG, Sandro; CARMO, Paulo Ricardo Viviurka do. Big data e ciência de dados: complementaridade conceitual no processo de tomada de decisão. Brazilian Journal of Information Science: research trends, Marília, SP, v. 13, n. 1, p. 56–67, 2019. DOI: 10.36311/1981-1640.2019.v13n1.06.p56. Disponível em: https://revistas.marilia.unesp.br/index.php/bjis/article/view/8315. Acesso em: 28 set. 2025.

BRASIL. Ministério do Esporte. Lei Geral de Proteção de Dados (LGPD). Brasília, 2024. Disponível em: https://www.gov.br/esporte/pt-br/acesso-a-informacao/lgpd. Acesso em: 28 set. 2025.

MATSUZAKA, Y. AI-Based Computer Vision Techniques and Expert Systems. AI, [S. l.], v. 4, n. 1, p. 289-302, 2023. Disponível em: https://doi-org.ez347.periodicos.capes.gov.br/10.3390/ai4010013.. Acesso em: 25 set. 2025.

FARAGALLAH, O. S.; EL-HOSENY, H. M.; EL-SAYED, H. S. Efficient brain tumor segmentation using OTSU and K-means clustering in homomorphic transform. Biomedical Signal Processing and Control, v. 85, 2023. Disponível em: https://www-sciencedirect-com.ez347.periodicos.capes.gov.br/science/article/pii/S1746809423001453. Acesso em: 25 set. 2025.

Tsai A. Y. Artificial intelligence in pediatric surgery. Seminars in Pediatric Surgery, 2024, v. 33, n. 1, p. 7, 2024.Disponível em: https://doi-org.ez347.periodicos.capes.gov.br/10.1016/j.sempedsurg.2024.151390. Acesso em: 25 set. 2025.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Deep Learning; MIT Press: Cambridge, MA, USA, 2016. Disponível em: < https://scholar.google.com/scholar_lookup?title=Deep+Learning&author=Goodfellow

, +I.&author=Bengio,+Y.&author=Courville,+A.&publication_year=2016>. Acesso em 28 de set de 2025.

Technology in Artificial Intelligence. Computational Intelligence and Neuroscience, [S. l.], v. 2022, ID 5658641, 2022. Disponível em: https://onlinelibrary.wiley.com/doi/10.1155/2022/5658641. Acesso em: 28 de set de 2025.

CARITÁ, E. C.; MATOS, A. L. M.; AZEVEDO-MARQUES, P. M. Ferramentas para visualização de imagens médicas em hospital universitário. Revista Brasileira de Radiologia, São Paulo, v. 37, n. 4, p. 273-278, ago. 2004. Disponível em: https://www.scielo.br/j/rb/a/pxsZnf4VPknBTkHJ8FmTnrB/?lang=pt. Acesso em: 28 de set de 2025.

TOP, Andrew; HAMARNEH, Ghassan; ABUGHARBIEH, Rafeeh. Active Learning for Interactive 3D Image Segmentation. In: FICHTINGER, Gabor; MARTEL, Anne; PETERS, Terry (Ed.). Medical Image Computing and Computer-Assisted Intervention – MICCAI 2011: 14th International Conference, Toronto, Canada, September 18-22, 2011, PROCEEDINGS, Part III. Heidelberg: Springer-Verlag, 2011. p. 603-610. (Lecture Notes in Computer Science, 6893). Disponível em: https://link.springer.com/chapter/10.1007/978-3-642-23626-6_74. Acesso em:14 de nov de 2025.

FREIHERR, G. : 3D imaging in medicine : synthesizing the third dimension. Diagnostic Imaging 9, 190-203 (November 1987) Galloway, L. and Thurstone, F.L. : Recent applications of parallel processing techniques to improve ultrasound B-mode images. Ultrasonic Imaging 8, n 1, p 69 (1986). Acesso em: 14 de nov de 2025.

HÖHNE, Karl H.; FUCHS, Henry; PIZER, Stephen M. (Ed.). 3D Imaging in Medicine: Algorithms, Systems, Applications. Berlin: Springer-Verlag, 1990. (NATO ASI Series F: Computer and Systems Sciences, v. 60). Disponível em: https://link-springer-com.ez347.periodicos.capes.gov.br/book/10.1007/978-3-642-84211-5. Acesso em: 14 de nov de 2025.

GIL, A. C. Como elaborar projetos de pesquisa. 7. ed. Baurieri, SP: Atlas, 2022. Acesso em: 16 de nov de 2025.

Arbelaez Ossa, L., Lorenzini, G., Milford, S.R. et al. Integrating ethics in AI development: a qualitative study. BMC Med Ethics 25, 10 (2024). https://doi.org/10.1186/s12910-023-01000-0 Acesso em: 20 de mar de 2026.

Corrêa, N.K., Santos, J.W., Galvão, C. et al. Crossing the principle–practice gap in AI ethics with ethical problem-solving. AI Ethics 5, 1271–1288 (2025). https://doi.org/10.1007/s43681-024-00469-8, Acesso em: 20 de mar de 2026.